PRÁCTICA 1
IA en la Industria Automotriz

Aplicaciones Avanzadas de la IA

Máster Universitario en Ingeniería Informática (2025/26)

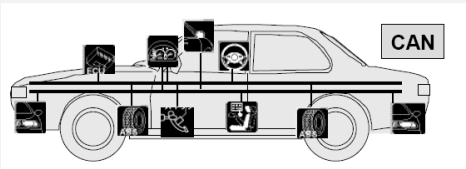

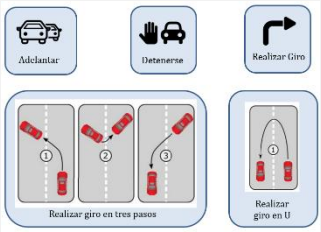

Introducción

En el ámbito de la conducción, el desarrollo de Sistemas Avanzados de Asistencia al Conductor (ADAS) tienen como objetivo hacer que la conducción sea más fácil y segura. En particular, uno de los aspectos relevantes de los ADAS consiste en detectar lo que el conductor está haciendo o lo que éste va a hacer. Esta detección de acciones puede realizarse mediante la observación directa, utilizando cámaras de visión frontal, o la observación indirecta, con el uso de determinados sensores en el vehículo.

El modelado del comportamiento del conductor (Driver Behaviour Modelling - DBM) es un problema de investigación que ha sido ampliamente estudiado en muchos trabajos de investigación [1] [2] [3] [4] [5].

En [6], se emplea un enfoque de aprendizaje automático para detectar y clasificar una amplia gama de maniobras de conducción, realizar una selección de sensores automovilísticos a gran escala y detectar la falta de atención de los conductores mediante el uso de los sensores disponibles en el parque automovilístico actual.

En [7] se propone una estructura jerárquica de la tarea del usuario en la carretera. En esa estructura, el rendimiento se divide en tres niveles de habilidades y control:

1) estratégico (planificación),
2) de maniobra (táctico) y
3) de control (operativo).

Los resultados externos de esos tres niveles son, respectivamente:

1) planes generales,
2) pautas de acción controladas y
3) pautas de acción automáticas.

En [8] se define una adaptación de ese modelo jerárquico y se incluye un nivel más: nivel de comportamiento. Este nivel se refiere a las condiciones previas y las características personales, y tiene la máxima prioridad porque estos aspectos influyen en gran medida en las decisiones de conducción en los niveles inferiores. La Figura 1 muestra la estructura jerárquica de estos niveles de conducción.

Otro aspecto muy importante son las entradas utilizadas en la tarea de modelado del conductor. En este sentido, los datos de los vehículos utilizados pueden provenir de la Red de Área de Control (Controller Area Network - CAN), de diferentes sensores (tales como radares, sensores de posición de carril, GPS, acelerómetros o giróscopos), o de diversas cámaras. Esta práctica se centra sólo en los datos del bus CAN.

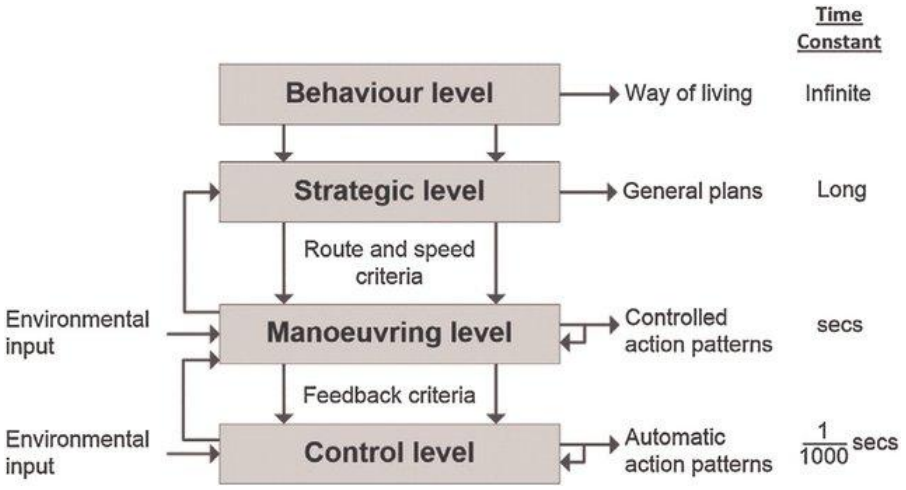

Figura 1. Diferentes niveles jerárquicos del automóvil [8]

Sin embargo, a pesar de las diferentes técnicas que pueden utilizarse para la detección de maniobras, en esta práctica se propone el uso (obligaotrio) de **sistemas difusos** (fuzzy systems).

Objetivo

El objetivo de esta práctica es el **diseño, implementación y evaluación de un sistema de inferencia difuso (sistema fuzzy) orientado a la detección de maniobras de conducción**. A partir de señales de conducción proporcionadas al alumno, el sistema deberá determinar, en cada instante o ventana temporal, la maniobra que está realizando el conductor. Cada grupo deberá seleccionar un mínimo de tres de las cinco maniobras disponibles, justificando el diseño del sistema fuzzy y analizando su rendimiento sobre los datos proporcionados.

Por otra parte, es obligatorio que se realice un pre-proceso de las señales obtenidas con la finalidad de desechar información redundante y obtener únicamente aquella información relevante para el objetivo que se quiere alcanzar. En este sentido, deberán realizarse los siguientes preprocesados:

1. **Limpieza de datos:** Si fuera necesario, deberán eliminarse aquellas características que son irrelevantes para el objetivo a cumplir, considerar valores nulos, discretizar o normalizar variables, etc.
2. **Segmentación temporal:** El uso de ventanas de tiempo debe ser considerado de forma obligatoria. Para ello, se utilizarán **ventanas deslizantes** que agrupen eventos en intervalos de tiempo.

La segmentación temporal es fundamental ya que no basta con analizar los datos de cada instante de tiempo de forma individual. Es imprescindible considerar un **conjunto de muestras consecutivas** para capturar patrones temporales, lo que supone implementar **ventanas deslizantes**.

Se debe considerar que existen dos tipos principales de ventanas deslizantes:

1. **Ventanas solapadas (overlapping)**: Cada nueva ventana incluye datos de la anterior, con un cierto grado de superposición.
2. **Ventanas no solapadas (sin overlapping)**: Cada ventana es independiente y no comparte datos con la anterior.

Como parte de los resultados, deberá analizarse si los resultados son mejores con ventanas solapadas o no solapadas.

Por otra parte, para obtener este objetivo, es necesario tener en cuenta los siguientes aspectos:

1) Estudiar los ficheros de maniobra, teniendo en cuenta que en los ficheros hay momentos de “no-maniobra”.
2) Tener en cuenta que un evento está distribuido a lo largo del tiempo, por lo que deberá variar el tamaño (duración) de la ventana deslizante.

Sistemas Expertos – Sistemas Fuzzy

Cuando hablamos de un sistema experto, normalmente nos referimos a un sistema software, un programa o un tipo de programas. Así, es experto siempre que de forma automática pueda implementar la pericia y la habilidad de un experto en un determinado dominio para resolver un problema.
Sin embargo, muchas herramientas de desarrollo de sistemas expertos comerciales incluyen diferentes aproximaciones a la incertidumbre con la teoría de Dempster-Shafer, modelos bayesianos y grados de certeza, pero no integran esta posibilidad con la representación y uso de conceptos y reglas borrosas. El Fuzzy Logic Toolbox (FLT) de MATLAB permite razonamiento borroso y con incertidumbre.

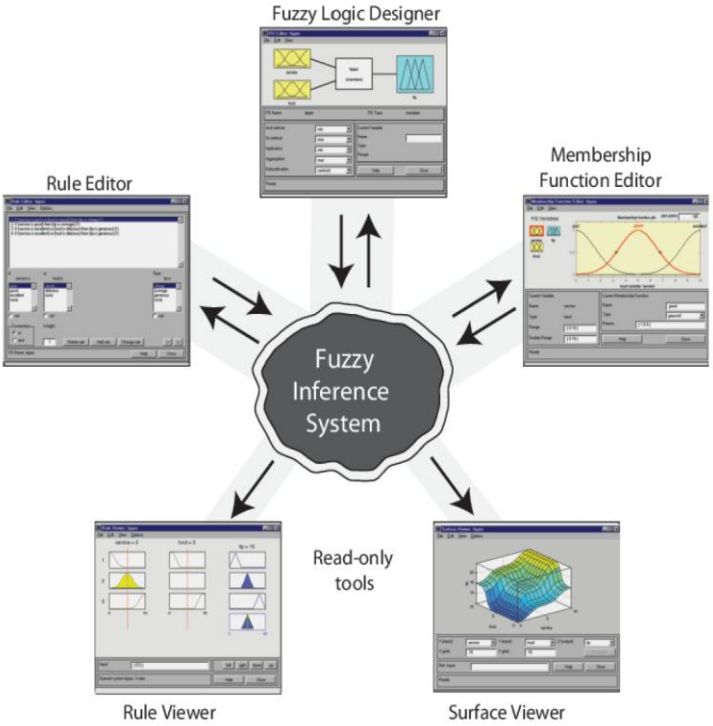

Figura 1. Componentes del Fuzzy Logic Toolbox (Fuente: mathworks.com)

FLT combina el razonamiento aproximado basado en los conjuntos y relaciones borrosas con factores de certeza asociados a reglas y hechos para razonar con incertidumbre. El Fuzzy Logic Designer permite, a alto nivel, manejar los principales aspectos del sistema borroso (variables de entrada/salida, nombres de variables, etc.).

En esta práctica, y con la ayuda del FLT, se pretenden desarrollar el siguiente sistema experto:

Cómo se han obtenido los datos a utilizar

Los datos con los que se realizará esta práctica se han obtenido utilizando un entorno de simulación de conducción. El entorno utilizado está basado en los sistemas avanzados de STISIM Drive® [9], e incorpora dispositivos de conducción que simulan el comportamiento de los que son instalados en un vehículo real. Teniendo en cuenta los controles del vehículo, el sistema de simulación incorpora un volante que simula el sistema de dirección asistida y unos pedales como los de un vehículo real, tal y como se puede ver en la Figura 2.

Figura 2. Entorno de Simulación

Este entorno proporciona una experiencia de simulación muy realista durante la recogida de datos de conducción. La metodología que se ha utilizado en el proceso de recogida de datos sobre las acciones y maniobras atómicas consiste en las siguientes fases:

1. **Diseño de un escenario de conducción simulado:** El escenario debe ser diseñado para utilizar elementos en la conducción tales como intersecciones, semáforos o vehículos lentos, que permitan la identificación visual de un conjunto de maniobras *M*. Además, no se podrán realizar diferentes tipos de maniobra de forma simultánea. La Figura 3 muestra una secuencia de imágenes (obtenidas del simulador de conducción) en las que el conductor ejecuta una maniobra de adelantamiento dentro de un escenario de conducción diseñado para tal fin.

Figura 3. Maniobra de adelantamiento

2. **Recopilación de datos:** Utilizando el escenario diseñado, los datos relacionados con los controles de conducción (es decir, las señales en bruto) son obtenidos y almacenados en tiempo real. También se almacenan los vídeos de la ejecución de la conducción. Como resultado de toda ejecución de un determinado escenario, se obtiene un archivo de datos en el que cada línea (es decir, instancia) se identifica con una marca de tiempo y contiene el conjunto de las señales generadas por los controles de conducción en ese instante de tiempo.

3. **Identificación visual de las maniobras:** Utilizando los vídeos grabados de cada simulación, se realiza un conjunto de ejemplos identificando los intervalos de tiempo en los que el conductor realiza una maniobra específica, $z = 0, 1 \mid m_i \in \mathrm{M}$

4. **Fusión de datos en bruto y etiquetas de maniobras:** Las instancias, que pertenecen a los intervalos de tiempo del conjunto de maniobras identificadas, se seleccionan del conjunto de datos. Como resultado de este proceso, se obtiene un nuevo archivo en el que cada instancia está compuesta por el conjunto de señales obtenidas en la fase 2, y el conjunto de etiquetas M obtenidas en la fase 3.

Para el desarrollo de esta práctica, se dispone de cinco maniobras diferentes:

- Adelantar,
- Detenerse,
- Realizar giro,
- Realizar giro en tres pasos,
- Realizar giro en U.

A continuación, se dan más detalles sobre estas dos últimas maniobras:

- Realizar giro en tres pasos: Método común para girar un vehículo en la dirección opuesta en un espacio limitado o en una carretera estrecha. El conductor tiene que utilizar la marcha adelante y la marcha atrás para cruzar la carretera, así después de girar debe ir marcha atrás y de nuevo hacia adelante para completar el giro. Obsérvese la Figura 4 a) que muestra gráficamente la maniobra.

- Realizar giro en U: diferencia del giro en 3 puntos, esta maniobra también se realiza en una carretera recta, pero con espacio suficiente para realizar toda la maniobra de una sola vez. Figura 4 a) que muestra gráficamente esta maniobra.

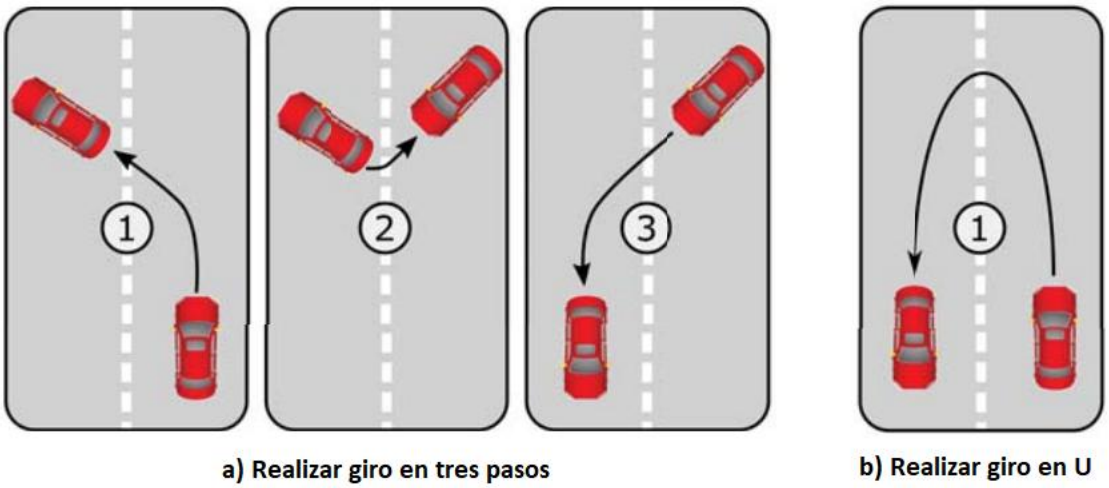

Figura 4. Maniobras: a) Giro en tres pasos y b) Giro en U.

Descripción de los datos a utilizar

Para esta práctica, se dispondrá de los datos recogidos del simulador STISIM Drive de 5 conductores diferentes de la forma indicada en el apartado anterior. Cada uno de los 5 conductores ha realizado cada una de las 5 maniobras explicadas anteriormente (Adelantar, Detenerse, Realizar giro, Realizar giro en tres pasos y Realizar giro en U) durante un periodo de tiempo. Este conjunto de datos se encuentra en AG con el nombre **ManiobrasSimulador.zip**

Así, por cada uno de los conductores se ha generado un fichero por maniobra en el que se almacenan todas las señales ("en crudo") del simulador recibidas cada instante de tiempo y si el conductor está realizando la maniobra correspondiente. Para ello, se indicará con 1 en el campo *Maneuver marker flag* si el conductor realiza dicha maniobra y un 0 en caso contrario. La cantidad de datos obtenidos por conductor y maniobra es muy alta, ya que estos datos se almacenan 20 veces por segundo.

Las señales almacenadas y que podrán utilizarse en esta práctica son:

- *Speed* - Velocidad,
- *RPM* - Revoluciones por minuto
- *Steering Wheel angle* - Ángulo del volante.
- *Gas Pedal* - Pedal del acelerador.
- *Brake Pedal* - Pedal del freno (b),
- *Clutch Pedal* - Pedal del embrague
- *Gear* – Marcha.

Además, en los conjuntos de datos se indican otros datos (*Long Dist, Lat Pos, Throttle input, etc…*) que no es necesario que sean utilizados en la práctica. También hay dos datos (*Left turn* y *Right turn*) que no pueden utilizarse para reconocer la maniobra de giros.

Así, por ejemplo, el conductor *driver1* almacena en el directorio de su mismo nombre los ficheros:

- *STISIMData_3step-Turnings.xlsx*
- *STISIMData_Overtaking.xlsx*
- *STISIMData_Stopping.xlsx*
- *STISIMData_Turnings.xlsx*
- *STISIMData_U-Turnings.xlsx*

Cada uno de estos ficheros almacena todos los datos del simulador obtenidos cada 1/20 segundos junto con un valor en el data "*Maneuver marker flag*" que indica si la

correspondiente maniobra se está realizando o no. Así, si el campo **"Maneuver marker flag"** es **0** indica que la acción no está realizándose. Sin embargo, el valor es 1 indica que se está ejecutando la maniobra correspondiente.

Por otra parte, el atributo "*Brake pedal force"* está relacionado con la fuerza que ejerce el conductor en el pedal, mientras que *"Brake pedal"* es la "fuerza" que está haciendo el propio coche para frenar. Como ejemplo, podéis considerar que, si se estuviera subiendo una pendiente, *"Brake Pedal Force"* debe ser mayor para obtener el mismo valor en *"Brake Pedal"*. Sin embargo, todas las simulaciones en las que se han obtenido los datos se han realizado sobre entornos sin pendientes, por lo que este valor estará totalmente correlado.

En relación con la normalización de datos, se puede considerar lo que consideréis más adecuado. Sin embargo, algo que debéis tener en cuenta es que hay instancias en las que el valor de *"gear"* es 0 durante el instante de tiempo en el que se está realizando un cambio en la marcha. Por ejemplo, en el paso de 3ª a 2ª, entre las instancias con valor 3 y las instancias con valor 2, hay una serie de instancias (normalmente son un número reducido) con valor 0. En este caso, debéis tener en cuenta que está en "punto muerto" por la transición entre una marcha y otra. Por lo tanto, independientemente del valor 0 "entre medias", la normalización en dicho caso se debe considerar como que se está decrementando de marcha.

Desarrollo de la práctica

Para alcanzar el objetivo de esta práctica, el alumno podrá seguir los sientes pasos:

1. Exploración y preprocesamiento de los datos

1.1 Carga de datos

a. Cargar los 5 ficheros Excel.

b. Visualizar algunas filas para entender el formato y las columnas.

1.2. Limpieza

a. Comprobar si hay valores perdidos, erróneos o atípicos (outliers).

b. Decidir cómo tratarlos (eliminar muestras, interpolar, etc.), justificándolo.

1.3. Normalización / escalado (si procede)

a. Opcionalmente, escalar señales a rangos más manejables para definir funciones de pertenencia (por ejemplo, normalizar velocidad entre 0 y 1).

1.4 Separación diseño / evaluación

a. Aunque no se use ML, es buena práctica elegir partes de los datos para:
   - Diseño/calibración del sistema (observación de patrones, ajuste de funciones de pertenencia).
   - Pruebas/evaluación final (datos no usados durante el diseño).

2. Diseño de ventanas temporales

La conducción es un fenómeno temporal: una maniobra no depende de una sola muestra, sino de una secuencia de acciones (acelerar, girar, frenar, etc.). Es importante "conservar en cierta forma la secuencialidad de las acciones atómicas".

En este punto, se debe debe:

1. Definir una ventana temporal (por ejemplo, de N muestras o de T segundos).
2. Posiblemente usar ventanas deslizantes (overlapping), por ejemplo:
   - Ventanas de 1–2 segundos con solapamiento del 50%, o una elección razonada.
3. Para cada ventana, extraer características a partir de las señales:
   - Media, máximo y mínimo de la velocidad.
   - Variación del ángulo de volante (por ejemplo, desviación estándar o rango).
   - Tiempo medio con acelerador/freno pisados.
   - Número de cambios de marcha, etc.

Estas características serán las entradas al sistema difuso.

Tarea:

- Elegir tamaño de ventana y solapamiento.
- Definir qué características vais a usar.
- Justificar brevemente las decisiones en la memoria.

3. Definición de las variables difusas

Para cada maniobra, escoged un subconjunto de variables de entrada que tengan sentido. Ejemplos:

- Para Adelantamiento:
  - Velocidad actual y variación de velocidad.

  - Posible cambio de carril (puede inferirse por el ángulo de volante y su evolución).
- Para Detenerse:
  - Velocidad media en la ventana.
  - Nivel de uso del freno.
- Para Giros / Giros en U / Giros en tres pasos:
  - Ángulo de volante y su variación.
  - Velocidad (suele reducirse).
  - Cambios de marcha.

4. Base de reglas difusas

Debéis construir una base de reglas IF–THEN basada en vuestro conocimiento y en la observación de los datos. Ejemplos orientativos:

- Adelantamiento
  - SI (Velocidad es Alta) Y (ÁnguloVolante cambia ligeramente) Y (Acelerador es Pisado) ENTONCES (Maniobra_Adelantamiento es Alta).
- Detenerse
  - SI (Velocidad es Baja) Y (Freno es Fuerte) ENTONCES (Maniobra_Detenerse es Alta).
  - SI (Velocidad es Media) Y (Freno es Suave) ENTONCES (Maniobra_Detenerse es Media).
- Giro
  - SI (Velocidad es Baja) Y (ÁnguloVolante es Izquierda) ENTONCES (Maniobra_Giro es Alta).

5. Implementación del sistema difuso

1. Implementar los sistemas difusos (uno por maniobra o un único sistema multi-salida).
2. Elegir el tipo de inferencias y desfuzificación (por ejemplo, Mamdani con centroide).
3. Aplicar el sistema a todas las ventanas de los ficheros de datos.

   Para cada ventana obtendréis, por ejemplo:

   - Grado de Adelantamiento: μ_1
   - Grado de Detenerse: μ_2

- Grado de Giro: μ_3
- Grado de Giro en U: μ_4
- Grado de Giro en 3 pasos: μ_5

Y se puede decidir que la maniobra detectada es la de grado más alto, siempre que supere un cierto umbral (p.ej. > 0.5). Si ningún grado supera el umbral, podréis considerar "ninguna maniobra".

6. Evaluación del sistema

Utilizando el atributo *Maneuver marker flag:*:

1. Definir una forma de comparar:
    - Si el flag = 1 para una maniobra, vuestro sistema debería asignarle un grado alto en esa zona.
    - Si el flag = 0, el grado debería ser bajo.
2. Proponer métricas de evaluación, por ejemplo:
    - Por maniobra:
        - Exactitud (accuracy) sobre ventanas etiquetadas / no etiquetadas.
        - Sensibilidad (TPR): porcentaje de ventanas de maniobra realmente detectadas.
        - Especificidad o tasa de falsos positivos.
    - Gráficas temporales:
        - Mostrar en un eje el Maneuver marker flag y en otro el grado difuso obtenido, para visualizar la calidad del sistema.
3. Analizar los resultados:
    - ¿En qué maniobras funciona mejor/peor?
    - ¿Qué ajustes de reglas o funciones de pertenencia mejorarían los resultados?
    - ¿Influye el tamaño de la ventana?

Papers Relacionados

Por último, destacamos dos investigaciones científicas que han utilizado estos datos (o muy similares) con una finalidad más compleja a la planteada en esta práctica, pero aplicando un tipo de sistemas denominados *sistemas autoadaptativo*[1]. A pesar de que las técnicas a aplicar en esta práctica son diferentes, pueden servir de referencias estas investigaciones para el tratamiento de los datos, análisis de resultados, etc…

Estas dos investigaciones se detallan a continuación:

1. Goran Andonovski, Oscar Sipele, José Antonio Iglesias, Araceli Sanchis, Edwin Lughofer, Igor Skrjanc: *Detection of driver maneuvers using evolving fuzzy cloud-based system*. 2020 IEEE Symposium Series on Computational Intelligence (Canberra, Australia). Pages: 700-706.

   Link: https://ieeexplore.ieee.org/document/9308520

2. Igor Skrjanc, Goran Andonovski, Agapito Ledezma, Oscar Sipele, José Antonio Iglesias, Araceli Sanchis. Evolving cloud-based system for the recognition of drivers' actions. Expert Systems with Applications 99*: 231-238 (2018)*

   Link: http://msc.fe.uni-lj.si/Papers/2016_%C5%A0krjanc_Driver_detection.pdf

Entrega de la práctica

- La entrega se realizará únicamente para obtener feedback.
- **La evaluación se realizará con un examen individual el 18 de marzo de 2026 (PEC 01).**
- La práctica deberá realizarse en grupos de 3 o 4 personas (y entregarse únicamente por uno de los integrantes del grupo)**.**
- La entrega de esta Práctica deberá realizarse por Aula Global antes del día 23 de febrero 2025 a las 15:00h.

Bibliografía

[1] K. Torkkola, S. Venkatesan y H. Liu, «Sensor sequence modeling for driving sequence modeling for driving,» de *Flairs conference*, 2005.

[2] A. Sathyanarayana, P. Boyraz y J. H. Hansen, «Driver behavior analysis and route recognition by Hidden Markov Models.,» de *2008 IEEE international conference on vehicular electronics and safety*, Columbus, OH, USA, 2008.

[3] C. Miyajima, Y. Nishiwaki, K. Ozawa, T. Wakita, K. Itou, K. Takeda y F. Itakura, «Driver modeling based on driving behavior and its evaluation in driver identification,» *Proceedings of the IEEE,* vol. 95, nº 2, pp. 427-437, 2007.

[1] https://es.wikipedia.org/wiki/Sistema_autoadaptativo

[4] B. Shi, L. Xu, J. Hu, Y. Tang, H. Jiang, W. Meng y H. Liu, «Evaluating driving styles by normalizing driving behavior based on personalized driver modeling.,» *IEEE Transactions on Systems, Man, and Cybernetics: SystemS,* vol. 45, nº 12, p. 1502–1508, 2015.

[5] A. Nakano, H. Okuda, T. Suzuki, S. Inagaki y S. Hayakawa, «Symbolic modeling of driving behavior based on hierarchical mode segmentation and formal grammar,» de *2009 IEEE/RSJ international conference on intelligent robots and systems*, St. Louis, USA, 2009.

[6] K. Torkkola, M. Gardner, C. Schreiner, K. Zhang, B. Leivian y H. Zhang, «Computational intelligence in automotive applications,» *Studies in computational intelligence,* vol. 132, pp. 59-77, 2008.

[7] J. A. Michon, «A critical view of driver behavior models: What do we know, what should we do?,» *Human behavior and traffic safety,* p. 485–520, 1985.

[8] M. Panou, E. Bekiaris y V. Papakostopoulos, «Modelling driver behaviour in european and international projects,» *Modelling driver behaviour in automotive environments: Critical issues in driver interactions with intelligent transport systems,* pp. 3-25, 2007.

[9] A. Amidon. [En línea]. Available: https://towardsdatascience.com/river-the-best-python-library-for-online-machine-learning-56bf6f71a403.

[10] Systems Technology, «Car driving simulator & simulation software,» 2016. [En línea]. Available: http:// www.stisimdrive.com/products/simulation-systems/m100-series ..

[11] J. A. Iglesias, P. Angelov y A. a. S. A. Ledezma, «Creating Evolving User Behavior Profiles Automatically,» *IEEE Transactions on Knowledge and Data Engineering,* vol. 15, nº 2, pp. 131-149, 2012.

[12] J. A. Iglesias, F. J. Ordoñez, A. Ledezma, P. de Toledo y A. Sanchis, «Evolving Activity Recognition from Sensor Streams,» de *2012 IEEE Conference on Evolving and Adaptive Intelligent Systems (EAIS 12)*, Madrid, Spain., 2012.

[13] F. J. Ordóñez, J. A. Iglesias, P. d. Toledo, A. Ledezma y A. Sanchis, «Online activity recognition using evolving classifiers.,» *Expert Systems with Applications,* vol. 40, nº 4, pp. 1248-1255, 2013.

[14] N. Abuali y H. Abou-zeid, «Driver behavior modeling : Developments and future directions,» *International Journal of Vehicular Technology,* pp. 1-12, 2016.

[15] A. Doshi y M. M. Trivedi, «Tactical driver behavior prediction and intent inference: A review,» de *IEEE conference on intelligent transportation systems*, Washington, DC, USA, 2011.

[16] W. Wang, J. Xi y H. Chen, «Modeling and recognizing driver behavior based on driving data: A survey,» *Mathematical Problems in Engineering,* pp. 1-20, 2014.

[17] A. A. Chaaraoui, P. Climent-Perez y F. Florez-Revuelta, «A review on vision techniques applied to human behaviour analysis for ambient-assisted living.,» *Expert Systems with Applications, ,* vol. 39, nº 12, pp. 10873-10888, 2012.

[18] T. Levermore, A. Ordys y J. Deng, «A review of driver modelling,» de *2014 UKACC international conference on control*, Loughborough, U.K, 2014.